准下最佳的直线?

要解决这两个问题，可以用下面介绍的回归分析的方法.

一般地，设给定一组有线性相关关系的成对数据(x_1,y_1)、(x_2,y_2)、…、(x_n,y_n)和一个线性方程(或称线性模型)

$$y=ax+b. \tag{①}$$

如何描述数据与此线性方程的贴近度呢?

当变量x取值$x_i(i=1,2,\cdots,n)$时，令$\hat{y}_i=ax_i+b$，它是变量y与x_i对应的理想值. 但数据中的y_i与$\hat{y}_i$不一定相同，它们的差$y_i-\hat{y}_i$称为在x_i处的**离差**(dispersion)，当$y_i-\hat{y}_i\geqslant 0$时称为正离差，而当$y_i-\hat{y}_i<0$时称为负离差. 显然，离差直观地描述了单对数据与线性方程①的贴近度.

由于离差可正可负，考虑数据整体与线性方程①的贴近度时，不能简单地用离差的代数和作为指标. 我们可以像计算方差那样，用离差的平方和

$$Q=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2$$

来刻画直线与点之间的拟合程度. Q称为**拟合误差**(fitting error)，它是一个很好的描述数据与线性方程①贴近度的指标. 我们把拟合误差取得最小值时得到的线性方程(线性模型)记为

$$y=\hat{a}x+\hat{b}, \tag{②}$$

并称之为变量y随x波动的**回归方程**(regression equation)或**回归模型**(regression model)，其中自变量x称为**解释变量**(explanatory variable)，因变量y称为**反应变量**(response variable). 回归方程所定义的直线称为**回归直线**(regression line)，回归方程的系数(或称回归模型的参数)$\hat{a}$与$\hat{b}$称为**回归系数**(regression coefficients). 由一组有某种线性关系的成对数据求其回归方程的方法称为一元线性**回归分析**(regression analysis).

回归系数$\hat{a}$与$\hat{b}$的计算公式如下：

$$\begin{cases}\hat{a}=\dfrac{\sum\limits_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})}{\sum\limits_{i=1}^{n}(x_i-\overline{x})^2}=\dfrac{\sum\limits_{i=1}^{n}x_iy_i-n\overline{x}\,\overline{y}}{\sum\limits_{i=1}^{n}x_i{}^2-n\overline{x}^2},\\ \hat{b}=\overline{y}-\hat{a}\overline{x}=\dfrac{\sum\limits_{i=1}^{n}y_i-\hat{a}\sum\limits_{i=1}^{n}x_i}{n},\end{cases} \tag{③}$$