课后阅读

一元线性回归系数公式的推导

在这个阅读材料中，我们将用初等的方法推导本节中所介绍的回归系数公式③.

先回顾我们的问题. 设有一组成对的数据(x_1,y_1)、(x_2,y_2)、…、(x_n,y_n)和一个 y 与 x 的线性关系 $y=ax+b$. 对给定 $i(i=1,2,\cdots,n)$，令$\hat{y}_i=ax_i+b$. 我们要“优化”线性关系，使离差 $y_i-\hat{y}_i$ 的平方和(即拟合误差)

$$Q=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2$$

达到最小值. 满足这个条件的线性关系是拟合数据的最佳选择.

为了找到最佳的线性关系，我们从略微不同的角度考察拟合误差. 把拟合误差改写成

$$Q=\sum_{i=1}^{n}(y_i-ax_i-b)^2.$$

由于数据$(x_i,y_i)(i=1,2,\cdots,n)$是给定的，故 Q 是 a、b 的二元函数. 于是问题化为：求变量 a、b 的最小二乘估计 $\hat{a}$、$\hat{b}$，使函数值达到最小.

令$\overline{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$ 与$\overline{y}=\frac{1}{n}\sum_{i=1}^{n}y_i$ 分别是数据x_i 与$y_i(i=1,2,\cdots,n)$的算术平均值，则

$$\begin{aligned}&(y_i-ax_i-b)^2\\&=\{(y_i-\overline{y})+[\overline{y}-(a\overline{x}+b)]-a(x_i-\overline{x})\}^2\\&=(y_i-\overline{y})^2+[\overline{y}-(a\overline{x}+b)]^2+a^2(x_i-\overline{x})^2-2a(x_i-\overline{x})(y_i-\overline{y})\\&\quad+2[\overline{y}-(a\overline{x}+b)](y_i-\overline{y})-2a[\overline{y}-(a\overline{x}+b)](x_i-\overline{x}).\end{aligned}$$

因为$\sum_{i=1}^{n}x_i=n\overline{x}$，所以$\sum_{i=1}^{n}(x_i-\overline{x})=\sum_{i=1}^{n}x_i-n\overline{x}=0$；同理$\sum_{i=1}^{n}(y_i-\overline{y})=0$. 这样，把上式对 i 从 1 到 n 求和，其最后两项所对应的和式都是 0. 于是，

$$\begin{aligned}Q&=\sum_{i=1}^{n}(y_i-\overline{y})^2+n[\overline{y}-(a\overline{x}+b)]^2+a^2\sum_{i=1}^{n}(x_i-\overline{x})^2-2a\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})\\&=\sum_{i=1}^{n}(y_i-\overline{y})^2+n[\overline{y}-(a\overline{x}+b)]^2+\sum_{i=1}^{n}(x_i-\overline{x})^2\left[a-\frac{\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})}{\sum_{i=1}^{n}(x_i-\overline{x})^2}\right]^2\\&\quad-\frac{\left[\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})\right]^2}{\sum_{i=1}^{n}(x_i-\overline{x})^2}\end{aligned}$$